DiffuScene: Denoising Diffusion Models for Generative Indoor Scene Synthesis

1. 개요

"실내 3D 씬(방 안 가구 배치)을 Denoising Diffusion Model로 생성하는 방법을 제안합니다."

게임 개발, VR, 인테리어 디자인 등의 분야에서 "방 안에 가구를 자연스럽게 배치하는 것"은 오랜 연구 과제입니다. 본 논문은 기존 GAN, VAE, Autoregressive 접근법의 한계를 Diffusion Model을 통해 동시에 극복하는 DiffuScene을 제안합니다.

2. 기존 접근법의 한계

접근법	대표 모델	문제점
GAN	DepthGAN	모드 붕괴 및 다양성 부족
VAE	Sync2Gen	다양성은 확보되나 생성 품질이 낮음
Autoregressive	ATISS	순차적 생성으로 인한 객체 간 관계 포착의 어려움 및 에러 누적

3. 핵심 아이디어

3.1 객체의 벡터 표현과 비순서 집합 구성

본 논문에서는 방 안의 각 가구를 하나의 벡터로 표현하고, 방 전체를 **비순서 집합(unordered set)** 으로 구성합니다:

$$\mathbf{o}_i = [\ell_i, \mathbf{s}_i, \cos\theta_i, \sin\theta_i, \mathbf{c}_i, \mathbf{f}_i] \in \mathbb{R}^D$$

속성	의미	차원
ℓ_i	위치 (x, y, z)	3
$\mathbf{s}_i$	크기 (w, h, d)	3
$\cos\theta_i, \sin\theta_i$	회전각	2
$\mathbf{c}_i$	클래스 레이블	C
$\mathbf{f}_i$	형상 코드 (Shape code)	F

객체 수는 방마다 다르므로, 최대 N개로 고정하고 빈 자리는 'empty' 클래스로 패딩합니다 (침실 N=13, 다이닝/거실 N=21).

"비순서(unordered)" 표현이 핵심적인 설계 선택입니다. ATISS와 같은 autoregressive 모델은 "침대 → 협탁 → 옷장" 순서로 하나씩 생성하지만, DiffuScene은 **모든 가구를 동시에** 디노이징합니다. 이를 통해 객체 간 관계(예: 침대 양쪽의 대칭적 협탁 배치)를 보다 효과적으로 포착할 수 있습니다.

3.2 1D 시퀀스에 대한 노이징 및 디노이징

이미지 diffusion이 (H × W × 3) 텐서에 노이즈를 추가하는 것과 마찬가지로, DiffuScene은 **(N × D) 텐서**에 동일한 DDPM 수식을 적용합니다:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \cdot \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

모든 객체의 모든 속성값(위치, 크기, 클래스, 형상코드)에 **동시에** 가우시안 노이즈가 추가됩니다. 이를 위해 각 속성은 다음과 같이 연속값으로 통일됩니다:

- **위치/크기/회전**: 본래 연속값이므로 별도의 변환 없이 사용
- **클래스**: one-hot 인코딩이 아닌 연속 벡터(ℝ^C)로 표현하며, 디노이징 후 argmax를 통해 카테고리를 결정
- **형상코드**: Shape Auto-encoder에서 추출한 latent vector(ℝ^F)를 [-1, 1] 범위로 스케일링

	이미지 Diffusion	**DiffuScene**
텐서 shape	H × W × 3	N × D
노이즈 대상	픽셀 RGB 값	객체 속성 값
공간 구조	2D grid (인접 픽셀 관계)	구조 없음 (비순서 집합)
Conv 타입	2D Conv	1D Conv
노이즈 수식	DDPM	동일 (DDPM)

4. 네트워크 구조: UNet-1D + Attention 디노이저

4.1 전체 아키텍처

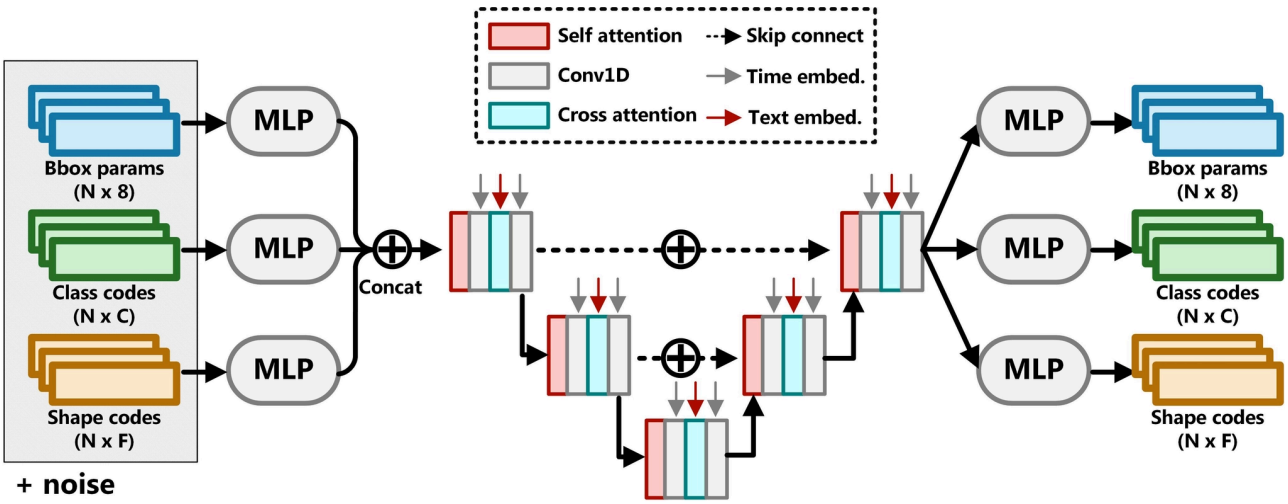

4.2 설계 근거

Conv1D 사용 이유:

- 본 모델은 2D 이미지가 아닌 1D 시퀀스(N개 객체)를 다루며, 각 객체가 하나의 "토큰" 역할을 수행합니다.

Self-Attention 도입 이유:

- Conv1D만으로는 객체 간 전역적 관계를 포착하기 어렵습니다.
- Self-Attention을 통해 "침대 옆에 협탁이 있으므로 반대쪽에도 협탁을 배치해야 한다"와 같은 전역적 관계를 학습할 수 있습니다.
- Ablation 실험에서 순수 Transformer(DALLE-2 스타일)의 FID 29.08 대비 UNet+Attention 조합이 FID 17.21로 크게 개선되었습니다.

인코더/디코더 3분할 이유:

- 단일 헤드를 사용할 경우 특정 속성(예: 위치 예측)에 편향될 위험이 있습니다.
- 분리된 헤드를 통해 각 속성에 독립적인 loss를 적용함으로써 균형 잡힌 학습이 가능합니다.

5. Shape Feature Diffusion: 대칭 배치의 핵심 메커니즘

5.1 Shape Auto-encoder

3D-FUTURE 데이터셋의 CAD 모델로 학습된 FoldingNet 기반 VAE의 구조는 다음과 같습니다:

3D 가구 CAD 모델 → 포인트 클라우드 (2,048점)

→ PointNet + Graph Conv 인코더 → 512d

→ μ, σ → reparameterization → 32d latent

→ FoldingNet 디코더 → 재구성

학습 목적함수는 다음과 같습니다:

$$L_{vae} = CD(\mathbf{P}_{in}, \mathbf{P}_{rec}) + 0.001 \cdot KL(\mathcal{N}(\mu, \sigma) \| \mathcal{N}(0, \mathbf{I}))$$

KL 가중치를 0.001로 설정하여 재구성 품질을 우선시하면서도 latent space의 정규화를 유지합니다.

5.2 Shape Diffusion이 대칭 배치에 기여하는 원리

기존 방식 (shape code 미포함):

- 디노이저가 "양쪽에 협탁이 위치한다"는 사실은 파악할 수 있으나, 두 협탁이 동일한 형상을 가져야 한다는 정보는 부재합니다.
- Shape retrieval 시 서로 다른 형상이 매칭될 수 있어 대칭이 깨지게 됩니다.

DiffuScene (shape code 함께 diffuse):

- Self-Attention이 디노이징 과정에서 "대칭 위치 + 동일 클래스 → 유사한 shape code"라는 패턴을 학습합니다.
- 양쪽의 shape code가 자연스럽게 수렴하여, 동일한 3D 모델이 매칭되고 진정한 대칭이 달성됩니다.

5.3 Ablation 실험 결과

설정	Sym (대칭 쌍)	FID	KID
C4: Shape diffusion 미적용	0.50	18.40	1.55
C5: Shape diffusion 적용	**0.72**	**17.21**	**0.70**
GT	0.71	-	-

Shape diffusion 적용 시 대칭 쌍이 44% 증가(0.50 → 0.72)하였으며, GT 수치(0.71)를 소폭 상회하는 결과를 보였습니다.

6. 학습 목적함수

6.1 L_sce — 노이즈 예측 Loss

DDPM의 표준 loss와 동일한 형태입니다:

$$L_{sce} = \mathbb{E}[\|\epsilon - \epsilon_\phi(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2]$$

3개의 분리된 헤드에서 각각 적용됩니다: $L_{sce} = L_{bbox} + L_{class} + L_{shape}$

한계: 이 loss는 각 객체를 독립적으로 복원하는 데 초점이 맞춰져 있어, 객체 간 물리적 겹침 문제를 다루지 못합니다.

6.2 L_iou — 겹침 방지 정규화 항

$$L_{iou} = \sum_{t=1}^{T} 0.1 \cdot \bar{\alpha}_t \cdot \sum_{\mathbf{o}_i, \mathbf{o}_j \in \tilde{\mathbf{x}}_0^t} \mathrm{IoU}(\mathbf{o}_i, \mathbf{o}_j)$$

구성 요소	역할
IoU(o_i, o_j)	두 바운딩 박스 간의 겹침 정도를 측정하며, 겹침이 존재할 경우 loss가 증가합니다
$\tilde{\mathbf{x}}_0^t$	타임스텝 t에서 예측된 깨끗한 씬의 근사값입니다
$\bar{\alpha}_t$ 가중치	노이즈가 적을 때(예측이 정확할 때) 강하게, 노이즈가 많을 때 약하게 적용됩니다
0.1 계수	보조 loss로서의 적절한 스케일을 유지합니다

6.3 최종 Loss

$$L_{total} = L_{sce} + L_{iou}$$

6.4 Ablation 실험 결과

설정	FID	KID	Sym	PIoU
C3: L_iou 미적용	17.93	1.29	0.64	0.47
C5: L_iou 적용	**17.21**	**0.70**	**0.72**	**0.43**
GT	-	-	0.71	0.30

L_iou 적용을 통해 PIoU가 감소(겹침 감소)하고 Sym이 증가(대칭 개선)하였습니다. 겹침을 방지하며 적절한 간격을 유지하는 것이 대칭 배치를 촉진하는 효과를 나타냅니다.

7. 응용: 하나의 모델을 활용한 세 가지 다운스트림 태스크

학습된 하나의 diffusion 모델을 “어떤 조건을 고정하고 나머지를 디노이징하느냐”에 따라 세 가지 태스크에 적용할 수 있습니다.

7.1 Scene Completion — 부분 씬의 자동 완성

- **입력:** M개의 기존 가구 → **출력:** N개 객체로 완성된 씬
- **방법:** 매 디노이징 스텝에서 기존 M개 객체는 원래 값으로 고정하고, 나머지 (N-M)개만 디노이징합니다.

- **핵심:** Self-Attention이 고정된 가구를 참조하여 자연스러운 배치를 생성합니다.

Room	Method	FID	KID	Sym
Bedroom	ATISS	27.14	1.56	0.01
	Ours	**22.16**	**1.02**	**0.70**
Living	ATISS	44.94	5.41	1.42
	Ours	**41.15**	**2.24**	**3.69**

7.2 Scene Re-arrangement — 객체 재배치

- **입력:** N개 가구의 종류, 크기, 형상 + 무작위 위치 → **출력:** 자연스러운 배치
- **방법:** 크기(s), 클래스(c), 형상코드(f)는 고정하고, 위치(ℓ)와 회전(θ)만 디노이징합니다.

$$p_\phi(\hat{\mathbf{u}}_{t-1}|\hat{\mathbf{u}}_t) := \mathcal{N}(\mu_\phi(\hat{\mathbf{u}}_t, t, \mathbf{v}), \sigma_t^2\mathbf{I})$$

7.3 Text-conditioned Scene Synthesis — 텍스트 기반 씬 생성

- **입력:** 텍스트 프롬프트 → **출력:** 텍스트 설명에 부합하는 3D 씬
- **방법:** 사전학습된 BERT 인코더로 텍스트 임베딩을 추출한 후, Cross-Attention을 통해 디노이저에 주입합니다.

기존 구조: Conv1D → Self-Attention → Conv1D

확장 구조: Conv1D → Self-Attention → Cross-Attention → Conv1D

↑ 텍스트 조건 주입

User Study 결과 (45명 참여, 225개 씬 평가):

평가 항목	DiffuScene 선호도
리얼리즘	**62%**
텍스트 매칭 정확도	**55%**

8. 실험 결과 분석

8.1 실험 세팅

- **데이터셋:** 3D-FRONT (침실 4,041 / 다이닝 900 / 거실 813)

- **학습 환경:** RTX 3090 1장, batch size 128, 100K epochs
- **디퓨전 설정:** T=1,000 steps, noise schedule 0.0001→0.02 (linear)

8.2 Unconditional 씬 생성 결과 (Table 1)

Method	FID↓	KID↓	SCA%	CKL↓
DepthGAN	40.15	18.54	96.04	5.04
Sync2Gen	31.07	11.21	82.97	2.24
ATISS	18.60	1.72	61.71	0.78
DiffuScene	**17.21**	**0.70**	**52.15**	**0.35**

> Bedroom 기준이며, 세 방 타입 모두에서 전 지표 1위를 달성하였습니다.

- **SCA 52.15%**: 분류기가 생성된 씬과 실제 씬을 거의 구별하지 못하는 수준입니다 (50%가 이상적).
- **KID 0.70 vs ATISS 1.72**: 분포 매칭 정확도가 약 2.5배 향상되었습니다.

8.3 Precision/Recall 분석 (Table 5)

Method	Precision	Recall
DepthGAN	58.05	31.66
ATISS	72.80	77.08
DiffuScene	**82.31**	**77.93**

> Bedroom 기준

품질(Precision)과 다양성(Recall) 모두에서 최고 성능을 달성하였습니다. GAN에서 나타나는 모드 붕괴 문제 없이, diversity-quality tradeoff에서 양측 모두를 충족시키는 결과입니다.

8.4 Ablation Study (Table 3)

설정	FID↓	KID↓	SCA%	CKL↓	Obj	Sym	PIoU
C1: Transformer only	29.08	4.59	73.63	0.76	5.10	0.70	0.46
C2: 단일 헤드	19.78	2.07	54.53	0.69	5.03	0.63	0.38
C3: L_iou 미적용	17.93	1.29	55.14	0.46	5.02	0.64	0.47
C4: Shape diffusion 미적용	18.40	1.55	55.42	0.66	4.97	0.50	0.52

설정	FID↓	KID↓	SCA%	CKL↓	Obj	Sym	PIoU
C5: Full model	**17.21**	**0.70**	**52.15**	**0.35**	**4.99**	**0.72**	**0.43**

각 설계 선택(UNet+Attention, 다중 헤드, IoU loss, Shape diffusion)이 최종 성능에 기여하고 있음을 확인할 수 있습니다.

9. 한계점

한계	설명
Shape retrieval의 제약	동일 클래스 내에서만 검색이 이루어져 스타일 불일치가 발생할 수 있습니다
텍스처 미생성	CAD 모델의 기존 텍스처를 그대로 사용하며, 텍스처 생성은 수행하지 않습니다
단일 방 한정	멀티룸 또는 전체 주거 공간 생성은 지원하지 않습니다
3D 라벨 의존성	2D supervision만으로는 학습이 불가능하며, 정확한 3D 정보(위치, 크기, 회전, 클래스, 3D 형상)가 필수적입니다.