SceneGraphNet: Neural Message Passing for 3D Indoor Scene Augmentation

Introduction

3D 모델과 장면(Scene)이 증가하면서, 3D 장면 안에서 물체에 관한 질의에 답하는 능력이 점점 더 중요해지고 있다. 이 논문이 다루는 대표적 질의는 다음과 같다.

> **"이 위치에 어떤 종류의 물체가 들어가면 주변 맥락과 잘 어울릴까?"**

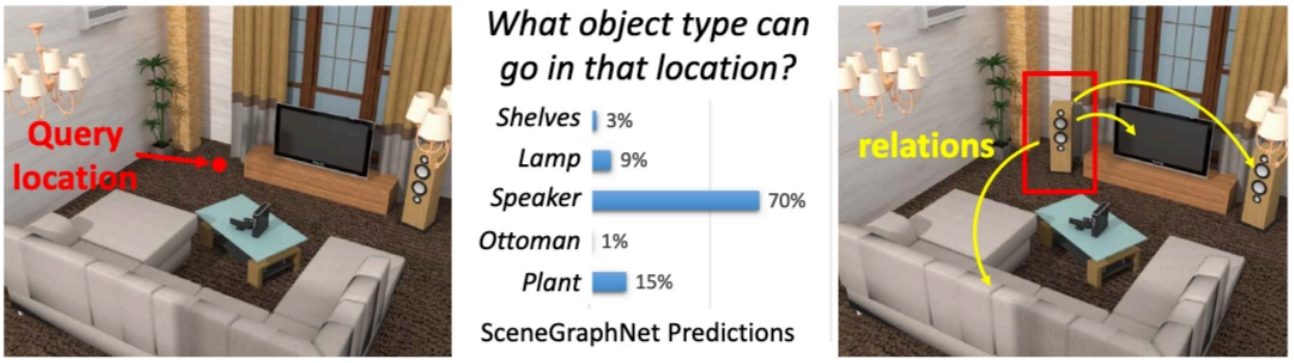

Figure1

위처럼 TV 스탠드 옆, 방 구석 근처의 위치(Query location)가 주어졌을 때, 그 자리에 들어갈 가능성을 확률 분포로 출력한다. (Speaker: 70%)

입력된 3D 장면 s 와 Query location p가 주어졌을 때, 그 위치에 들어갈 수 있는 물체 카테고리에 대한 확률 분포 $P(C \mid p, s)$ 를 예측하는 것이 핵심 과제

활용 분야

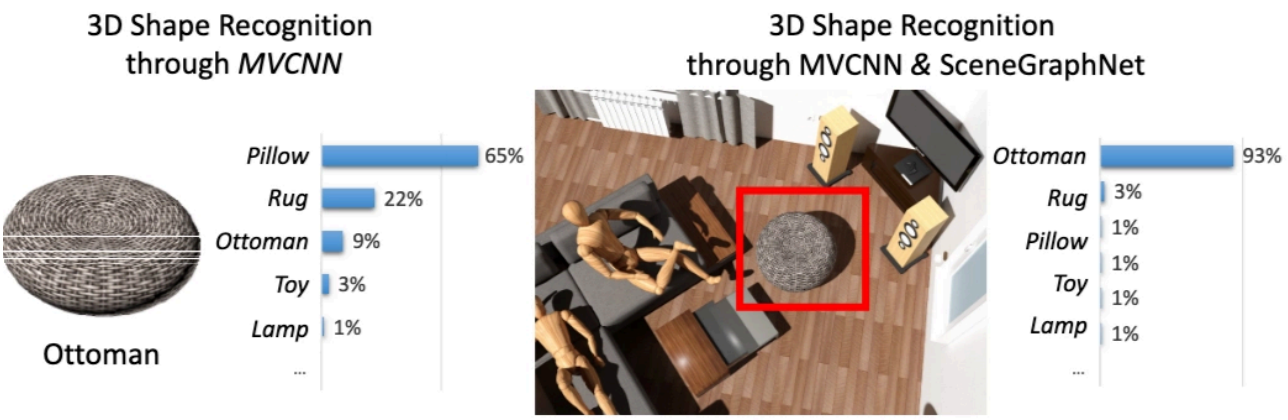

Figure2

1. **맥락 기반 3D 물체 인식 (Context-based 3D object recognition)**

개별 물체의 모양(shape)만 보고 카테고리를 분류하는 기존 접근은 유사한 모양을 가진 다른 카테고리 물체(예: 베개 vs 오토만)에 취약하다. **주변 장면 맥락**을 고려하면 인식 정확도가 크게 향상 (Figure 2 참고)

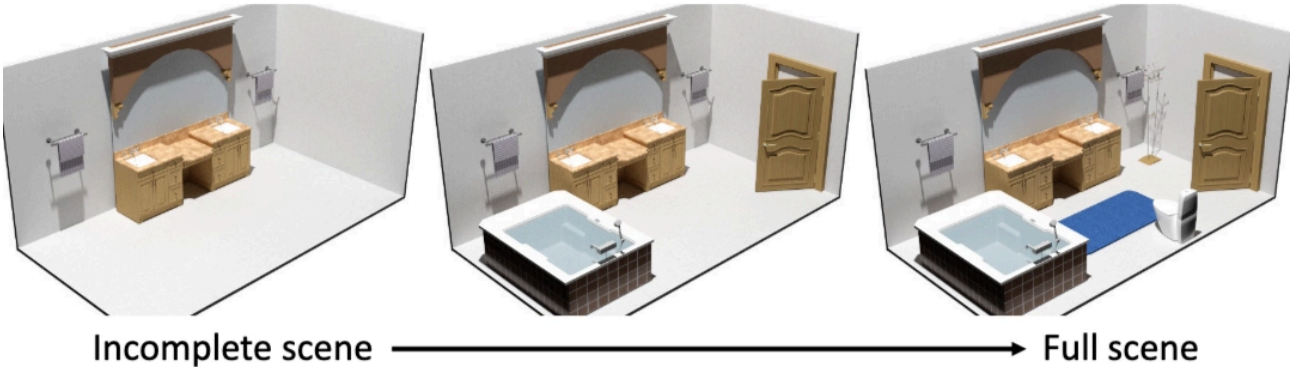

Figure 3

1. **자동 3D 장면 채우기 (Scene population / iterative scene synthesis)**

   다양한 위치에서 분포를 평가하여 가장 확률이 높은 위치와 카테고리를 뽑으면, 불완전한 장면을 점진적으로 완성할 수 있다 (Figure 3 참고)

2. **인터랙티브 3D 장면 디자인 보조**

   디자이너가 장면을 모델링할 때 **추천 카테고리 리스트**를 확률순으로 제공

Method

1. 입출력

- 입력
  - 장면 s: 3D 물체들이 배치된 실내 공간
  - 장면 속 각 물체는 카테고리(sofa, table 등)가 이미 라벨되어 있음
  - 질의 위치 p: 장면 내의 한 3D 좌표점
- 출력
  - $P(C \mid p, s)$ — 위치 p에 들어갈 수 있는 카테고리들의 확률 분포

2. Message Passing

주변 노드가 보내는 메시지를 받아 맥락을 파악할 수 있는 Representation Vector를 누적한다. 이 과정을 반복하여 멀리 있는 물체들의 영향을 반영한다.

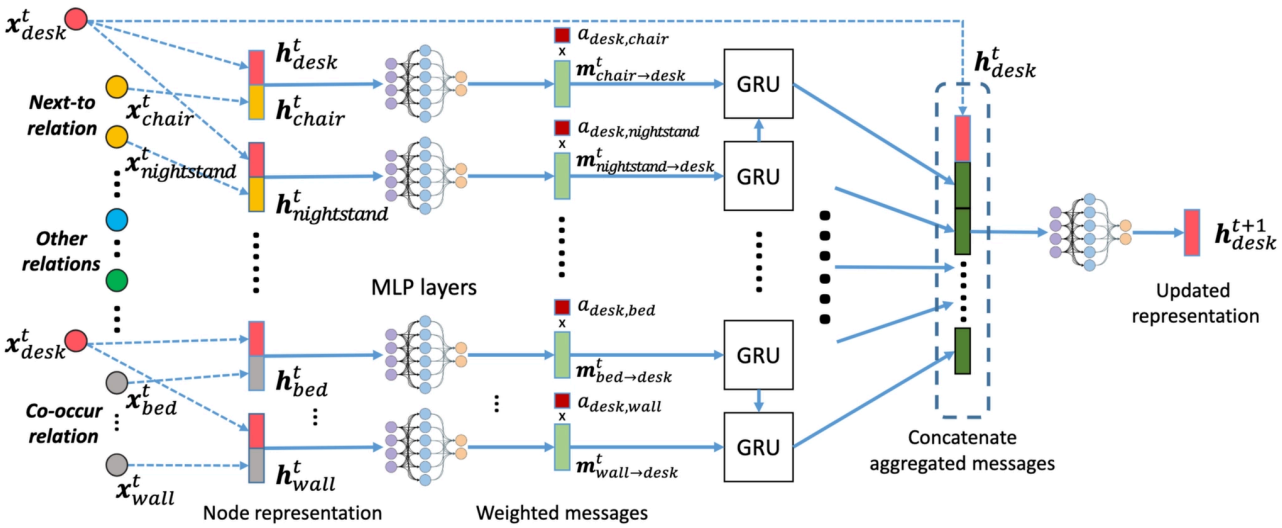

2.1. Initialization

각 객체(노드) i는 다음 정보를 포함하는 Shape Representation x_i로 벡터화

- $x_i = [c_i, p_i, d_i]$
  - c_i: 카테고리 one-hot 벡터
  - $p_i \in \mathbb{R}^3$: 물체 중심점의 3D 위치
  - $d_i \in \mathbb{R}^3$: oriented bounding box의 크기

그리고 MLP 레이어에 통과하여 “무엇이 어디에 얼마나 큰 크기로 있는가”를 100차원으로 임베딩

$h_i^{(0)} = f_{init}(x_i; w_{init})$

2.2. Messages

시점 t에서 노드 k에서 노드 i로 전달되는, 관계 유형 r에 해당하는 메시지는 다음과 같이 계산

$m_{k\to i}^{(r,t)} = f_{\text{msg}}^{(r)}(h_k^{(t)},\ h_i^{(t)};\ w_{\text{msg}}^{(r)})$

- $f_{\text{msg}}^{(r)}$: 2-layer MLP, 관계 r마다 **별도의 가중치** $w_{\text{msg}}^{(r)}$ 를 가짐
- 출력 차원: 100

> **Note**
>
> 관계 유형마다 파라미터를 분리하는 이유는 support, surrounding 같은 다른 관계는 서로 다른 방식으로 정보를 요약해야하기 때문

2.3. Attention

각 메시지에 가중치를 $a_{k,i}$를 곱하는 attention을 도입

$a_{k,i} = f_{\text{att}}(x_k,\ x_i;\ w_{\text{att}})$

- f_{att}: 2-layer MLP + sigmoid → 출력이 $[0, 1]$ 스칼라
- **주목할 점**: f_{att}는 **학습된 잠재 표현 h가 아닌, raw 표현 x를 입력으로 받음**

  → 학습 수렴이 더 안정적
- $a_{k,i} \approx 0$ 이면 해당 엣지는 사실상 무시 → 테스트 시 엣지를 **동적으로 제거**하여 계산량을 줄일 수 있음
- x에 위치가 포함되므로, $a_{k,i}$는 물체 간 거리와 상관관계를 갖는 경향이 있음

2.4. Message aggregation

노드 i가 관계 r을 통해 받는 메시지들 $\{m_{k\to i}^{(r,t)}\}_{k\in N(i)}$을 **GRU 시퀀스**로 순차 집계

$$g_{i,j}^{(r,t)} = f_{\text{GRU}}^{(r)}\big(g_{i,j-1}^{(r,t)},\ a_{k,i}\cdot m_{k\to i}^{(r,t)};\ w_{\text{GRU}}^{(r)}\big)$$

- $j = 1, \ldots, |N(i)|$: 집계 순서 인덱스
- GRU의 첫 입력은 all-zero
- GRU 파라미터 $w_{\text{GRU}}^{(r)}$도 **관계 유형별로 별도**
- 마지막 GRU 출력이 최종 집계 메시지 $g_i^{(r,t)}$

GRU를 사용한 이유는 ablation study에서 GRU 방식이 가장 우수했기 때문

2.5. Node representation update

집계된 메시지들을 concatenate 한 뒤, 이전 표현과 함께 MLP를 통과시켜 다음 시점의 표현을 만든다.

$$h_i^{(t+1)} = f_{\text{upd}}\Big(h_i^{(t)},\ \text{Concat}\big(\{g_i^{(r,t)}\}r \in R\big);\ w_{\text{upd}}\Big)$$

- R: 전체 관계 유형 집합
- f_{upd}: 2-layer MLP

3. Graph Structure and Object Relationships

노드들 간에 연결하는 가장 간단한 방법은 유클리드 거리 기반으로 계산해서 연결하는 것이지만, 가까운 정도의 기준이 모호하고 거리의 임계값/이웃 수를 정하기 어려움

따라서 세분화된 관계 유형 + dense graph가 더 나은 성능을 보여줌

6가지 관계 유형

#	관계 이름	방향성	설명
1	**Supporting**	유향 (directed)	노드 i의 물체가 노드 k의 물체 "위에 놓여 지지"함. Bounding box 비교로 검출.

#	관계 이름	방향성	설명
2	**Supported-by**	유향	Supporting의 **역방향** 관계. **별도의 MLP 가중치**로 비대칭 메시지를 학습 → 단순 대칭으로 두는 것보다 성능 향상.
3	**Surrounding**	유향	같은 크기의 물체들이 중앙 물체를 **대칭(반사·회전)** 으로 둘러싸는 경우. (예: 침대 양옆의 나이트스탠드 쌍)
4	**Surrounded-by**	유향	Surrounding의 역방향. 중앙 물체 → 둘러싼 물체들로의 엣지. **별도의 MLP 가중치 사용.**
5	**Next-to**	무향 (undirected)	두 물체가 같은 지지면(supporting surface) 위에서 서로 인접할 때. 양 방향 메시지를 **동일한 MLP**로 계산.
6	**Co-occurring**	무향	두 물체가 같은 장면에 함께 존재한다는 것 자체만으로 연결. → **완전 연결(fully connected) 그래프**를 형성. 장거리 의존성을 포착.

4. Prediction

4.1. Empty Node

- 특별 노드 m을 생성:
  - 카테고리·크기·3D 위치(one-hot·scale·position) 벡터는 **all-zero**
- 다른 노드들과 관계 유형들에 따라 연결 (유향 관계의 방향은 상대 위치로 판별 가능)
- 이 노드 + 엣지가 최종 scene graph s를 완성

4.2. 반복적 메시지 전달

- **동기식 업데이트**: 모든 메시지를 계산한 뒤 한꺼번에 송신
- 반복 횟수 $T = 3$ (저자들의 실험적 선택)

반복 횟수에 따른 성능 (top-5 accuracy)

반복 수	Top-5 정확도
$t = 1$	72.7%
$t = 2$	88.2%
$t = 3$	89.5%
$t > 3$	약 89% 주위에서 진동

4.3. 카테고리 예측

마지막 시점의 empty 노드 표현 $h_m^{(T)}$를 MLP + softmax에 통과

$P(c \mid p, s) = f_{\text{pred}}\left(h_m^{(T)};\, w_{\text{pred}}\right)$

4.4. 크기 예측

추가 MLP가 $h_m^{(T)}$에서 **물체의 oriented bounding box 크기** d_m 를 Regression Prediction

5. Training

5.1. 데이터 생성 방식

1. 훈련 장면을 하나 선택
2. 그 안에서 "floor"와 "wall"을 제외한 물체 중 하나를 **무작위로 제거**
3. 제거된 물체의 위치를 질의 p로 두고 제거된 카테고리를 맞히도록 학습

5.2. Loss Fuction

- 카테고리: **categorical cross-entropy**
- 크기: **L2 loss** (ground-truth bounding box 크기와의 차이)