Text2NeRF: Text-driven 3D scene generation with neural radiance fields

Authors	J. Zhang *et al.*
Venue	CVPR
Year	2022
Present	2026/04/28
URL	chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://arxiv.org/pdf/2305.11588
Summary	• Generation based on NeRF • Diffusion-based approaches utilizing semantic priors
Last modified	2026년 4월 28일 오후 9:15

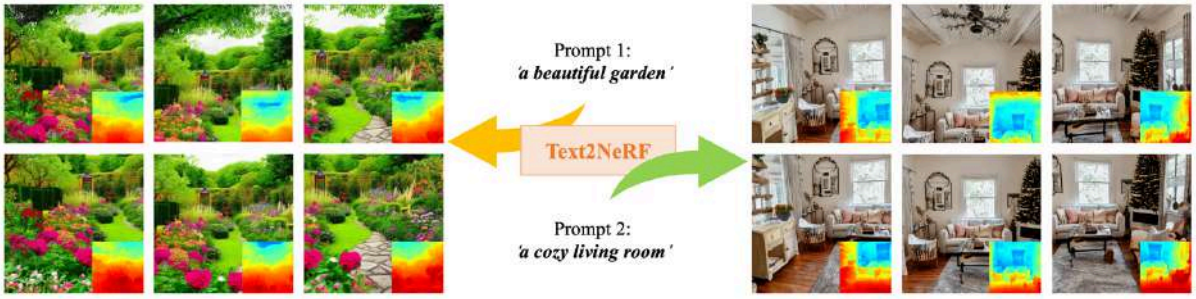

- **Text prompt만을 사용하여 3D scene 생성**
- **Progressive inpainting and updating (PIU)** 전략과 two-step **depth alignment** 과정을 사용하여 **시점 간 일관성(view consistency)을 강화**함
- **Depth loss**를 도입하여 NeRF가 더 안정적으로 **3D geometry**를 학습할 수 있도록 함

Abstract

Text-driven 3D scene generation은 비디오 게임, 영화 산업, 그리고 메타버스와 같이 대형 3D 장면이 필요한 task에 널리 적용될 수 있다.

하지만, **현존하는 text-to-3D generation 방법**들은 **간단한 기하 구조의 사실성이 부족한 3D 객체**를 생성하는 수준에 그친다.

본 논문에서는 오직 텍스트 프롬프트만으로부터 복잡한 기하 구조의, 높은 사실성을 가진 넓은 범위의 3차원 장면을 생성하는 **Text2NeRF**를 제안한다.

이를 위해 저자들은 **사전학습된 text-to-image diffusion 모델을 활용**하여 **NeRF**의 3차원 장면 재현을 **텍스트로 주어진 장면 표현에 충실하도록 제한**한다.

특히, 저자들은 다음과 같은 **prior**를 활용하여 3차원 장면을 구성한다.

- **diffusion으로부터 얻은 text-related image → content prior**
- **monocular depth estimation 결과 → geometric prior**

Content prior와 geometric prior들은 NeRF 모델을 업데이트하는 데 사용된다.

서로 다른 **view에서의 질감 및 기하 구조의 일관성**을 위하여, 저자들은 다음과 같은 두 가지 전략을 사용하여 novel view synthesis를 수행한다.

1. **Progressive scene inpainting**
2. **Progressive scene updating**

제안된 방법은 추가 학습이나 데이터를 필요로 하지 않고, **오직 장면에 대한 자연어 설명만을 입력**으로 사용한다.

실험 결과들은 제안된 Text2NeRF이 기존 모델들 photo-realistic, multiview consistent, 그리고 다양한 자연어 프롬프트로부터의 3차원 장면 다양성 측면에서 능가함을 보인다.

1. Introduction

최근의 텍스트→이미지 생성 분야의 비약적인 발전으로 인해 zero-shot 텍스트→3D 생성에도 큰 관심이 쏠리고 있다.

자연어 프롬프트를 이용해 원하는 3차원 모델을 구체화하는 방식은 직관적이므로, 3D 모델링 작업에 있어 생산성을 높이고 비전문가의 진입 장벽을 낮출 수 있다.

그러나 텍스트→이미지 생성과는 달리, 텍스트→3D 생성을 위한 짝지어진(paired) 데이터셋은 많지 않다.

이러한 데이터 한계를 우회하기 위해 **초기 연구**들은 CLIP이나 image diffusion과 같은 **사전학습된 텍스트-이미지 모델의 deep prior**를 이용해 3차원 표현을 최적화하였다.

이러한 연구들이 큰 성공을 거두었음에도 불구하고, 생성 결과는 여전히 **단순한 기하 구조와 비현실적인 스타일의 3D 장면**에 제한되는 경향이 있다.

저자들은 이와 같은 한계의 원인으로 사전학습된 모델로부터 얻은 **deep prior**을 지목한다.

Deep prior들은 고수준 의미 정보를 전달할 수 있지만, **저수준 세부 묘사는 충분히 반영하지 못할 것**이라 추측하기 때문이다.

반면, **후속 연구**인 `SceneScape`와 `Text2Room`은 텍스트-이미지 diffusion model이 생성한 컬러 **이미지를 직접 사용**하여 3D 장면 복원을 유도한다.

위의 방법들은 사실적인 3D 장면을 생성할 수 있지만, 다음과 같은 한계가 있다:

- 주로 실내 장면에만 초점을 맞추고 있다.
- **명시적 3D 메시 표현**을 사용하는데, '단순한 삼각분할' 때문에 **기하 왜곡 문제**가 발생하기 쉽다.
    - **컬러 이미지 → 깊이 추정 → depth 기반의 3D recon**으로 3D 장면을 구성하는 점을 만든다.
    - 이때 **깊이 추정 과정 자체에도 noise** 가 많다.
    - 삼각형들을 실제 기하 구조가 아닌 단순한 방법(최근접 point 기준 등)을 사용하여 구성한다.
- 따라서, 기존에 제안된 방법들은 대규모 실외 장면으로 확장하기 어렵다.

따라서, 본 연구는 **복잡한 기하 구조의 장면의 모델링에 더 유리한 NeRF**를 3D 표현으로 활용하면서도 NeRF와 텍스트-이미지 확산 모델의 장점을 결합한 Text2NeRF를 제안한다.

NeRF를 3차원 표현으로 활용함으로써 특히 **깊이 불연속이 발생하는 영역에서 삼각 메시 표현으로 인해 생기는 아티팩트를 효과적으로 줄일 수 있다**.

또한, 추가적인 3D supervision이나 다중 시점 학습 데이터 없이도, **사전학습된 텍스트-이미지 확산 모델을 이미지 prior으로 사용하여 초기 상태의 NeRF 최적화**를 제약한다.

Text2NeRF는 다음과 같은 두 가지 prior을 사용함으로써 더욱 정교한 기하 구조와 사실적인 텍스처를 갖는 3D 장면을 생성할 수 있다.

- **Content prior** : **diffusion 모델**을 이용하여 생성된, **텍스트와 관련된 이미지**
- **Geometric prior** : **monocular depth estimation**으로 얻은, 장면의 **depth map**

두 prior를 함께 사용하여 NeRF 표현의 파라미터를 최적화한다.

저자들은 또한, **서로 다른 시점 간의 일관성을 보장**하기 위해 점진적 인페인팅 및 업데이트 방법으로 **PIU (Progressive inpainting and updating)**을 제안한다.

PIU는 **카메라 궤적을 따라 3D 장면을 시점별로 확장**하는 전략이다.

한 시점에서 학습된 장면 정보는 업데이트된 NeRF에 누적되며, 이후 시점의 렌더링에도 반영된다.

이로써 **이미 학습된 영역을 중복 생성하는 문제가 줄어들고**, 장면의 연속성과 시점 일관성이 향상된다.

또한, 이미지 RGB 손실 외에도 **L2 depth loss**를 도입하여 depth-aware NeRF 최적화를 수행함으로써 **NeRF 모델의 수렴 속도와 안정성을 향상**시킨다.

서로 다른 시점에서의 depth map은 독립적으로 추정되므로 **겹치는 영역에서 불일치가 생길 수 있다**는 점을 고려하여, 서로 다른 시점 간 대응점들의 **깊이 값을 정렬**하는 **two-stage depth alignment 방식**도 함께 제안한다.

이와 같은 구성 요소들 덕분에, Text2NeRF는 자연어 설명만으로도 다양하고 고품질이며 시점 일관적인 3D 장면을 생성할 수 있다.

제안된 방법은 일반성이 높아 **실내, 실외, 심지어 예술적 장면까지 폭넓은 3D 장면을 생성**할 수 있다.

또한, **시점 범위에 제한되지 않기 때문에 360도 장면 생성**도 가능하다.

저자들은 실험을 통하여 Text2NeRF가 정성적, 정량적 측면 모두에서 기존 방법들을 능가함을 보였다.

본 연구의 기여는 다음과 같이 요약할 수 있다.

- 확산 모델과 NeRF를 결합한 텍스트 기반의 사실적 3D 장면 생성 프레임워크를 제안하며, 이를 통해 **자연어 프롬프트만으로 다양한 실내 및 실외 장면의 zero-shot 생성**이 가능함을 보인다.
- 3D 장면에 대해 **시점 일관적인 새로운 콘텐츠를 점진적으로 생성하는 PIU 전략**을 도입하고, 시점별 업데이트 과정에서 NeRF 모델에 다중 시점 제약을 제공하기 위한 support set을 구성한다.
- Depth loss를 도입하여 depth-aware NeRF 최적화를 수행하고, 서로 다른 시점에서 추정된 depth의 불일치를 제거하기 위해 2단계 깊이 정렬 전략을 제안한다.

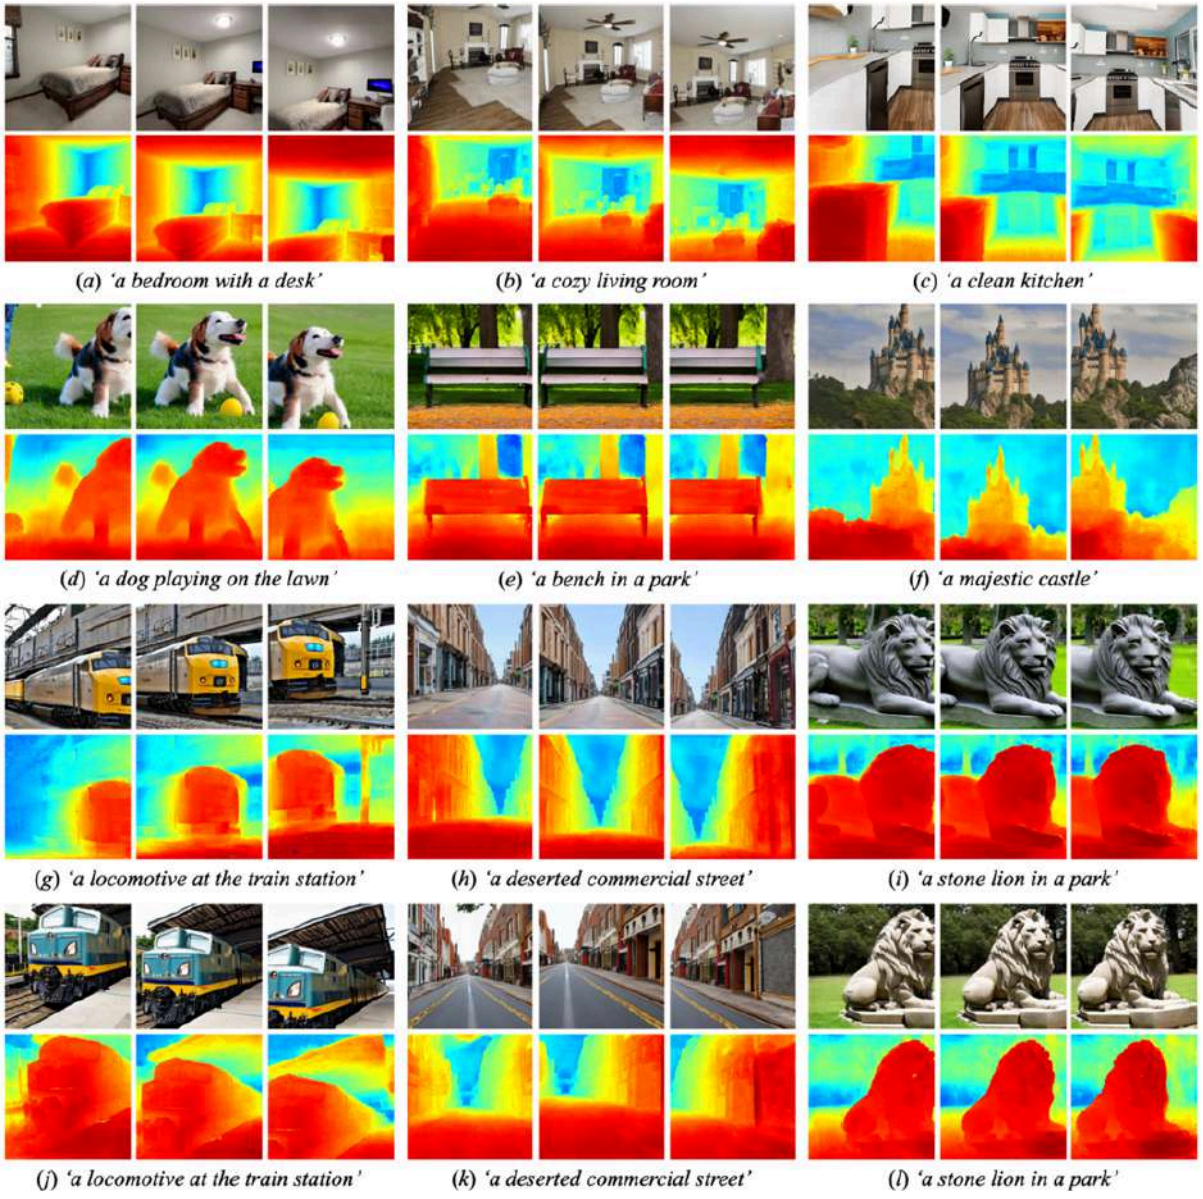

2. Related Work

▼ Text-Driven 3D Generation

3D 생성이라는 task는, **다양한 시점에서 일관된 3차원 기하 구조**와 **고품질 텍스처**를 구성하는 것을 목표로 한다.

초기 연구들인 `3D-GAN`, `PointFlow`, `ShapeRF` 등은 **복셀**이나 **포인트 클라우드 표현**을 기반으로 **특정 범주에 한정**된 **무텍스처 기하 형상 생성**에 주로 초점을 맞추었다.

이후 `PlatonicGAN`, `HoloGAN`, `VolumeGAN` 은 **자동차, 얼굴, 실내 장면** 등 **특정 범주의 데이터셋**으로부터 구조 및 텍스처 표현을 학습하여, **텍스처를 포함한 3D 장면**을 생성하고자 하였다.

이러한 방법들은 특정 범주에 대해서는 유망한 3D 장면 생성 결과를 보였지만, **텍스트 기반 생성 과제를 처리할 수는 없었다**.

텍스트 기반 3D 생성을 실현하기 위해, `Text2Shape` 는 특정한 **장면-텍스트 paired 데이터셋**으로부터 **두 개의 인코더 네트워크**를 사용하여 텍스트와 3D 모델 사이의 교차 모달 연결을 임베딩 공간에서 학습하였다.

텍스트-이미지 생성 기법의 급속한 발전에 힘입어, **최근 연구**들은 **사전학습된 텍스트-이미지 모델**을 활용하여 **3D 장면 생성**을 유도하고자 한다.

예를 들어, `CLIP-Mesh` 는 사전학습된 CLIP 모델의 지도 아래 의미 기반 최적화 전략을 사용하여 3D 메시의 형상과 텍스처를 추론한다.

CLIP-Mesh와 유사하게, `PureCLIPNeRF` 와 `DreamFields` 는 사전학습된 CLIP 모델을 이용해 암시적 NeRF 표현을 갖는 3D 객체 생성을 유도한다.

CLIP 모델과 비교했을 때, **최신 텍스트-이미지 diffusion model**은 방대한 학습 데이터와 우수한 구조 덕분에 훨씬 **강력한 생성 능력**을 가진다.

이에 따라 `DreamFusion` 과 `SJC` 는 사전학습된 텍스트-이미지 확산 모델로부터 깊은 **의미 prior**를 추출하기 위해 SDS(score distillation sampling) loss를 제안하였고, 이를 사용해 3D 모델의 생성 네트워크를 지도한다.

이후 `Magic3D`, `Latent-NeRF`, `3DFuse` 와 같은 후속 연구들이 **SDS 손실의 제약** 아래 생성되는 3D 모델의 품질을 향상시키기 위해 제안되었다.

이러한 방법들은 입력 프롬프트와 관련된 다양한 3D 모델을 생성할 수 있게 해주지만, **사전학습된 모델의 고수준 의미 프라이어만을 사용하여 3D 생성을 제약**하기 때문에, **복잡한 기하 구조와 고충실도 텍스처를 갖는 사실적인 3D 장면은 생성하지 못한다**.

반면 본 연구의 방법은 사전학습된 **텍스트-이미지 확산 모델로부터 저수준 콘텐츠 프라이어와 깊이 프라이어를 추론**하며, 이를 통해 사실적인 3D 장면의 기하 및 텍스처 세부 정보를 효과적으로 제약한다.

보다 최근에는, 본 연구와 독립적이면서 동시에 제안된 `SceneScape` 와 `Text2Room` 이 본 연구와 유사한 텍스트-3D 생성 방식을 제안하였다.

그러나 이들은 생성 과정에서 **명시적 폴리곤 메시를 3D 표현으로 사용**하며, 이로 인해 **실외 장면 표현이 제한**되고, **mesh 면이 결합되는 영역**에서 늘어난 기하 구조와 흐릿한 **아티팩트가 발생**한다.

반면 본 연구의 암시적 NeRF 표현과 복원 전략은 특정 장면 조건에 의존하지 않고도 세밀한 기하 구조와 텍스처를 모델링할 수 있으므로, 실내뿐 아니라 실외 장면까지 생성할 수 있다.

▼ Novel View Synthesis from a Single Image

3D 표현에 의해 제약되는 일부 NVS 방법들은 단일 이미지로부터 3D 일관성을 갖는 시각적 경험을 생성할 수 있다.

예를 들어, `SVS`, `3DP`, `3D-Ken-Burns`와 같은 **기존의 3D photography 방법**들은 MPI(multi-plane images) 또는 LDI(layered depth images)를 3D 표현으로 사용하고, 이후 **사전학습된 인페인팅 모델**을 활용하여 **가려진 영역을 보완**함으로써 그럴듯한 새로운 시점을 합성한다.

그러나 이러한 방법들은 특정한 3D 표현 방식의 한계로 인해 **작은 범위의 시점만 생성**할 수 있다.

반면, 또 다른 부류의 방법들은 **단일 시점 이미지 정보**를 **전통적인 3D 모델로 매핑**함으로써 3D 복원과 새로운 시점 합성을 수행한다.

예를 들어, `SynSin`은 **예측된 깊이 정보**를 바탕으로 이미지 특징을 **포인트 클라우드**로 변환하고, 렌더링된 **feature map을 디코딩**하여 3D 장면의 새로운 시점을 합성한다.

`PixelSynth`는 **픽셀 색상을 직접 3D 점에 대응**시켜 포인트 클라우드를 구성하며, 새로운 시점에서 누락된 정보를 채우기 위해 **outpainting 및 refinement** 모듈을 도입한다.

`Worldsheet`는 입력 이미지와 예측된 깊이에 따라 **평면 메시 시트를 워핑**하여 3D 장면의 새로운 시점을 합성한다.

직관적으로는, 텍스트-이미지 모델이 생성한 이미지를 이들 방법 중 하나에 그대로 적용하여 새로운 시점으로 확장하는 것이 텍스트 기반 3D 생성의 단순한 전략처럼 보일 수 있다.

그러나 이러한 단순한 접근은 몇 가지 한계를 갖는다.

- 이들 방법의 scene extrapolation은 입력 이미지 자체에만 기반하며, **텍스트 프롬프트에 의해 조건화되지 않는다**.
- 따라서 생성된 **장면의 범위**는 의미적 일관성을 유지하기 위해 **입력 이미지 주변으로 제한**된다.

반면 본 연구의 방법은 주어진 텍스트 프롬 프트에 의해 구동되어 새로운 시점에서 새로운 콘텐츠를 생성할 수 있다.

따라서 시점 범위에 제한되지 않으며, 텍스트 설명과 일관된 360도 장면 생성도 가능하다.

또한 이들 방법에서 사용되는 거친 메시나 포인트 클라우드와 같은 명시적 3D 표현은 정교한 결과를 렌더링하는 데 한계가 있지만, 본 연구는 암시적 NeRF 표현을 활용하므로 고충실도 세부 표현 및 렌더링에 더 우수하다.

3. Method

저자들은 text-driven 3D scene generation framework를 제안한다.

이 프레임워크는 3차원 장면을 점진적으로(progressive) 생성한다.

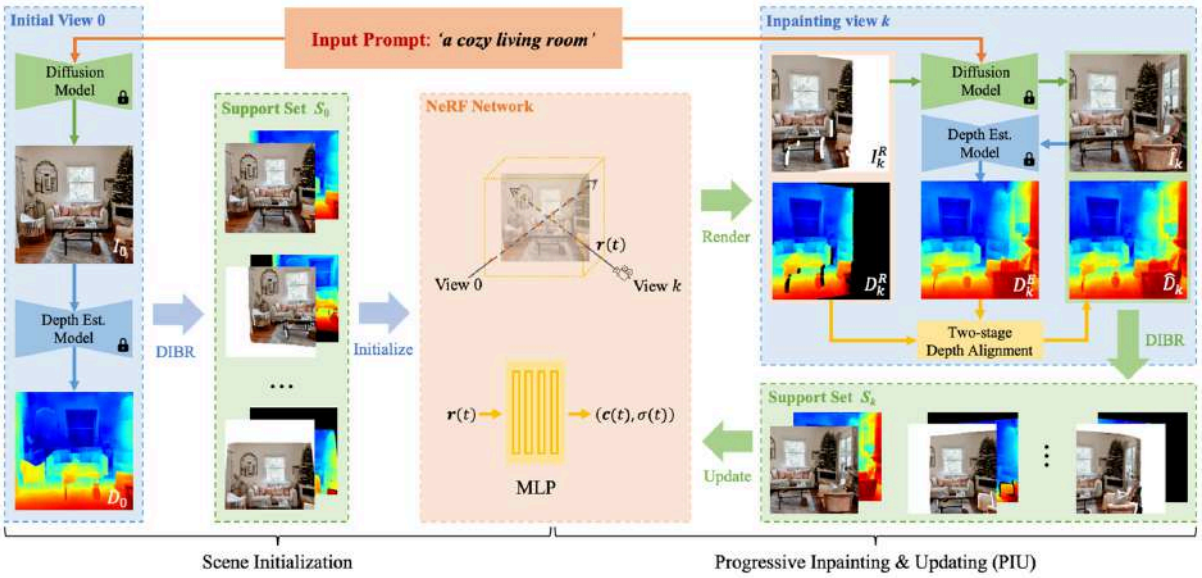

Figure 2.

3.1. Scene Initialization

Content Generation

Text prompt p에 대한 초기 장면을 얻기 위하여, 저자들은 **사전학습된 diffusion model f_d를 사용**한다.

생성된 이미지 I_0는 random Gaussian noise ϵ에 대하여 다음과 같이 나타낸다:

$$I_0 = f_d(\epsilon \mid p)$$

이미지 I_0의 3차원 기하 정보는 주어져 있지 않기 때문에, **monocular depth estimator f_e를 활용**하여 **geometric inference** D_0를 얻는다.

$$D_0 = f_e(I_0)$$

초기 장면 I_0와 depth map D_0은 3D 장면 초기화를 위한 **support set**을 구성한다.

3D Scene Representation

기존의 explicit representation들과 달리, NeRF는 **복잡한 장면에서의 기하 정보를 표현**하는 데 강점이 있다.

저자들은 **NeRF network** f_θ를 사용하여 3차원 장면을 표현한다.

f_θ에 다음과 같은 **volume rendering** 방식을 적용하여 **픽셀 색상**을 다음과 같이 구한다:

$$\mathbf{C}(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t))\, dt$$

($\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ 는 카메라 중심 $\mathbf{o}$에서 $\mathbf{d}$ 방향으로 발산된 광선에서 샘플링된 점들의 자취)

기존의 NeRF는 색상을 예측할 때 광선의 방향인 $\mathbf{d}$를 포함한다.

하지만, **Text2NeRF에서 활용되는 NeRF는 반사광 효과를 피하기 위하여 $\mathbf{d}$을 사용하지 않는다.**

이에 더하여, 저자들은 **NeRF 최적화에 depth constraint를 도입**하여 **depth-aware NeRF 최적화**를 수행하고, 수렴 속도를 높인다.

마지막으로, f_θ을 사용하여 **depth value** $z(\mathbf{r})$은 다음과 같이 계산한다:

$$z(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))t\ dt$$

▼ Notation

- I_i^R: Rendered image
- D_i^R: depth map
- $(I_i^R, D_i^R) = VR(f_\theta \mid i)$: volume rendering on view i

Support Set

Multi-view supervision이 어렵기 때문에, 한 장의 이미지 I_0과 대응되는 depth map D_0만을 사용하여 NeRF를 학습시키는 것은 overfitting과 기하구조의 모호성을 일으키기 쉽다.

이와 같은 문제를 극복하기 위하여 저자들은 **Depth Image-Based Rendering (DIBR) method**를 채택하여 **support set S_0을 구성**하고, **3D 장면의 초기화**에 사용한다.

DIBR은 **view P_0에서의 이미지 I_0에 나타난 장면이 다른 view P_i에서 어떻게 보일지를 추정**하는 과정이다.

P_0에서의 이미지 I_0 상의 특정 [픽셀값, depth]=$[q, z]$는 P_i에서 다음과 같이 보인다 (K: intrinsic) :

$$[q_{0\to i}, z_{0\to i}]^T = KP_iP_0^{-1}[q, z]^T$$

편의를 위하여, view P_0에서 P_i으로 전환하는 DIBR 과정을 다음과 같이 나타낸다: $DIBR_{0\to i}$

기준 view P_0에 대하여, z축 상의 위치는 고정한 상태로 radius $\zeta = 0.2$을 가지는 원 위에서 uniform하게 $\xi = 8$개의 view를 샘플링하였다. (상하좌우, 대각선)

최종적으로는 P_0와 $P_1, \cdots, P_8$의 9개 view으로 구성되는 3D point들로 장면을 초기화하고 NeRF를 학습시키기 시작한다.

3.2. Text-Driven Inpainting

DIBR을 사용하여 초기화된 장면으로 NeRF를 학습시키면, 임의의 view에 대해 3D 장면을 렌더링할 수 있다.

하지만 **초기 view P_0와 차이가 큰 view에서 렌더링**한다면, 렌더링된 이미지에 **불완전한 영역**이 존재하게 된다.

이와 같은 **missing region을 보완**하기 위하여 저자들은 **사전학습된 diffusion model** f_d을 기반으로 만들어진 **text-driven inpainting method**을 활용한다.

먼저, 현재 시점까지 학습된 NeRF으로 새로운 카메라 시점 P_k에서 이미지를 렌더링하여 I_k^R을 얻는다.

이후 I_k^R의 missing region을 채우기 위하여 다음과 같은 과정을 거친다.

- **DIBR**을 사용하여 **이전 단계에서 NeRF의 최적화에 이미 사용된 view의 이미지**들을 모두 P_k으로 **warping**한다.
- warping된 이미지들로는 표현되지 않는 **빈 부분을 mask** M_k**으로 정의**한다.
- 사전학습된 diffusion model f_d에 **불완전한 이미지** I_k^R**, mask** M_k**, 그리고 텍스트 프롬프트** p을 입력하여 **inpainting**을 수행하여 보완된 이미지 $\hat{I}_k$을 얻는다.

$$\hat{I}_k = f_d(I_k^R, M_k \mid p)$$

Inpainting과정은 확률적이기 때문에, 같은 diffusion model f_d과 input을 사용하더라도 inpainted image는 다르게 생성될 수 있다.

따라서 저자들은 생성 과정을 $J = 30$**번 반복**하여 **candidate images** $\hat{I}_k^j$을 얻고, **최초 이미지** I_0**와 가장 유사한 것을 하나 골라 사용**한다.

여기서 '유사하다'는 CLIP 인코딩 결과의 유사성을 의미한다.

$$\hat{I}_k = \arg\min_j \cos(E_{CLIP}(I_0), E_{CLIP}(\hat{I}_k^j))$$

3.3. Depth Alignment

Depth estimation은 각 이미지에 대하여 독립적으로 수행되기 때문에, **서로 겹치는 부분에서는 depth misalignment**가 발생할 수 있다.

예를 들어, inpainted view의 depth map D_k^E와 NeRF를 사용하여 렌더링된 이미지의 depth map D_k^R은 일치하지 않을 수 있다.

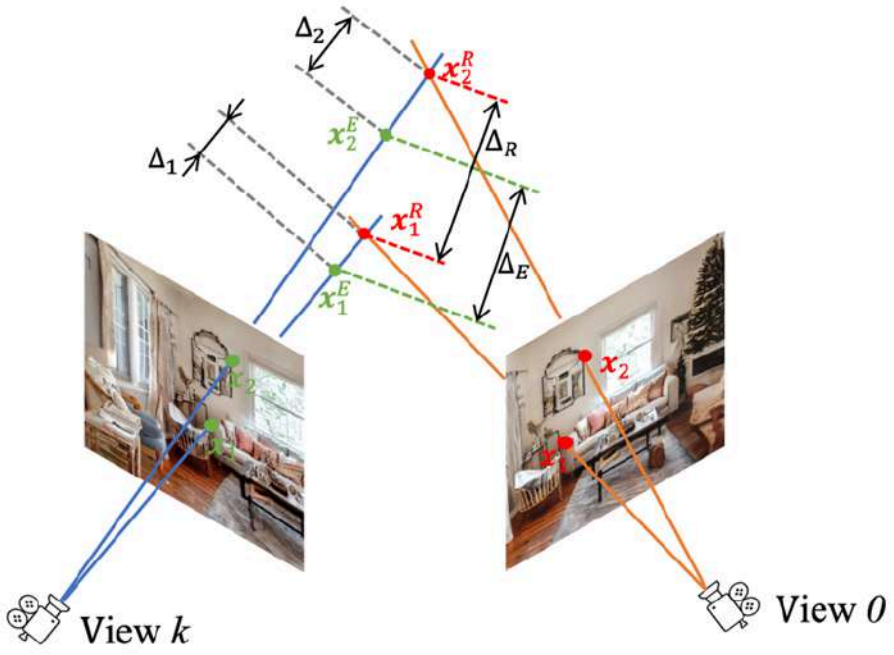

이러한 **depth misalignment는 두 가지 형태**로 나타난다:

- **scale difference(또는 distance difference)**
  - 서로 다른 시점에서 정렬된 두 픽셀에 대응하는, 3차원 공간상의 두 점 사이의 거리 차이
  - Δ_E, Δ_R
- **value difference(또는 depth value differene)**
  - 특정 한 점의 깊이값 자체의 차이
  - Δ_1, Δ_2

이 중 **scale difference**가 나타난 경우에는 **단순한 shift 연산으로 두 점을 정렬할 수 없다.**

한 점의 depth를 맞추더라도 다른 점은 여전히 정렬되지 않은 상태로 남기 때문이다.

다음과 같은 **두 가지 depth map이 겹치는 영역**에서 나타나는 **scale 및 value difference를 보정**하기 위하여 저자들은 **two-stage depth alignment**를 도입한다.

- **Depth map** D_k^R : NeRF f_θ을 사용하여 추정
- **Depth map** D_k^E : monocular depth estimator f_e으로 추정

1. **전역적 정렬:** 평균적인 스케일 차이와 값 차이 보정

D_k^R와 D_k^E의 평균적인 스케일 차이와 값 차이를 결정하기 위하여, 저자들은 서로 겹치는 영역에서 M**개의 무작위 픽셀 쌍**을 골라 그들의 3D 좌표를 구한다. 이를 $\{(\mathbf{x}_j^R, \mathbf{x}_j^E)\}_{j=1}^M$이라고 나타내자.

다음으로, **scaling score** s와 **depth offset** δ를 사용하여 **두 depth map의 평균적인 스케일 차이와 값 차이를 근사**한다.

$$s = \frac{1}{M-1}\sum_{j=1}^{M-1}\frac{\|\mathbf{x}_j^R - \mathbf{x}_{j+1}^R\|}{\|\mathbf{x}_j^E - \mathbf{x}_{j+1}^E\|}$$

$$\delta = \frac{1}{M}\sum_{j=1}^{M}(z(\mathbf{x}_j^R) - z(\hat{\mathbf{x}}_j^E))$$

($\hat{\mathbf{x}_j^E} = s \cdot \mathbf{x}_j^E$는 스케일링된 포인트, $z(\cdot)$은 포인트의 depth 값)

이제 depth map D_k^E을 D_k^R에 맞추어 전역적으로 정렬한다: $D_k^{\text{global}} = s \cdot D_k^E + \delta$

2. **국소적 정렬:** 사전학습된 depth alignment network를 fine-tune하여 미세 보정

D_k^R과 D_k^E의 차이는 완전히 선형적이지 않기 때문에 **국소적인 차이를 추가적으로 보정**하기 위하여 **pixel-to-pixel network** f_ψ를 사용한다.

각 view에 대하여, 사전학습된 **depth alignment network** f_ψ의 파라미터 ψ을 다음과 같은 LSE를 최소화시키도록 최적화한다.

$$\min_\psi \left\| \left(f_\psi(D_k^{\text{global}}) - D_k^R \right) \odot M_k \right\|_2$$

마지막으로, 최적화된 f_ψ를 사용하여 **locally aligned depth map**을 얻는다.

$$\hat{D}_k = f_\psi(D_k^{\text{global}})$$

3.4. Progressive Inpainting and Updating

Iteration k에서 inpainted image $\hat{I}_k$와 aligned depth map $\hat{D}_k$를 얻은 뒤, DIBR을 사용하여 support set S_k을 구성하고, 이를 통해 NeRF를 업데이트한다.

이때 인페인팅 과정에서 시점 간 일관성을 보장하고 기하 및 외형의 모호성을 방지하기 위하여, 저자들은 **NeRF를 시점별로 순차적으로 업데이트**하는 progresive inpainting and updating 전략을 제안한다.

이 전략에서는 **각 인페인팅 단계가 끝날 때마다 NeRF f_θ를 업데이트**한다.

이렇게 함으로써 **인페인팅된 콘텐츠는 이후의 렌더링에 지속적으로 반영**되며, 이후의 view 렌더링에서 인페인팅 처리가 되지 않는다.

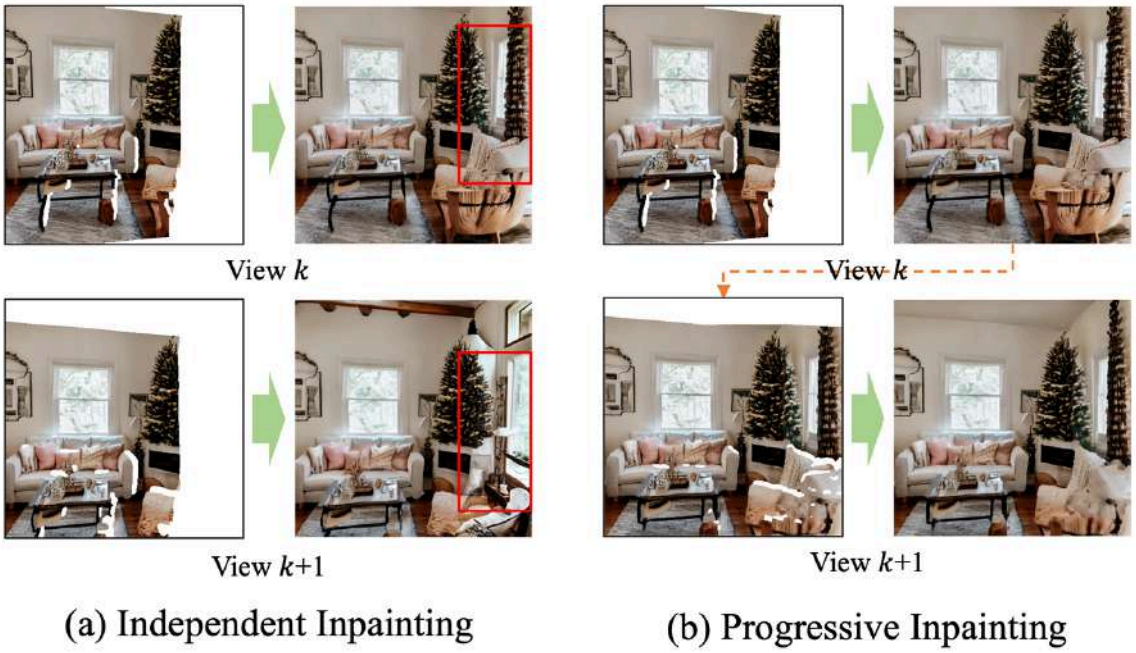

(a) Independent Inpainting (b) Progressive Inpainting

▼ **Algorithm**

Algorithm 1 Progressive Inpainting & Updating Strategy

Input:

prompt p;
pre-trained diffusion model f_d;
pre-trained depth estimation model f_e;
initialized NeRF f_θ;
views to be updated $\mathbf{V} = \{1, 2, \cdots, N\}$;
views already updated $\widetilde{\mathbf{V}} = \{0\}$.

Updating Process:

for k in $\mathbf{V}$ **do**
  rendering $(I_k^R, D_k^R) = VR\,(f_\theta \mid k)$
  mask calculation $M_k \leftarrow \cap\{DIBR_{n\to k}\}$, where $n \in \widetilde{V}$
  if $sum(M_k) > 0$ **then**
    text-driven inpainting $\hat{I}_k = f_d\left(I_k^R, M_k \mid p\right)$
  else
    continue
  end if
  depth estimation $D_k^E = f_e(\hat{I}_k)$
  depth alignment $\hat{D}_k = align(D_k^E \mid D_k^R, M_k)$
  support set $\mathbf{S}_k \leftarrow \cup\{DIBR_{k\to support_views}\}$
  update views updated $\widetilde{\mathbf{V}} = \widetilde{\mathbf{V}} \cup \{k\}$
  update NeRF model $f_\theta \leftarrow \mathbf{S}_k$
end for

Return: updated NeRF f_θ

3.5. Training and Implementation Details

Training Objective

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{RGB}} + \lambda_d \mathcal{L}_{\text{Depth}} + \lambda_t \mathcal{L}_T$$

($\lambda_d = 0.005$, $\lambda_t = 1000$)

▼ **RGB loss $\mathcal{L}_{\text{RGB}}$**

렌더링된 이미지의 색상값 C^R과 diffusion model f_d으로 생성된 이미지의 색상값 C 사이의 L2 loss

▼ **Depth loss $\mathcal{L}_{\text{Depth}}$**

렌더링된 깊이 D^R과 정렬된 추정 깊이 $\hat{D}$ 사이의 L2 loss

▼ **Transmittance loss $\mathcal{L}_T$**

카메라 광선이 estimated depth $\hat{z}$에 도달하기 전, NeRF가 empty denisty를 출력하도록 유도한다.

$$\mathcal{L}_T = \|T(t) \cdot m(t)\|_2$$

($m(t)$: 마스크 지시 함수, $t < \hat{z}$일 때 1, 그렇지 않으면 0을 출력한다.)

4. Experiments

4.1. Setup

Baseline Methods

Text-driven 3D method에서의 성능을 7개의 baseline 모델과 비교하여 제시한다.

Metrics

Scene generation은 GT 이미지가 없기 때문에, 생성된 이미지 그 자체만을 가지고 품질을 평가할 수 있는 metric을 사용하였다.

▼ **Blind/referenceless image spatial quality evaluator (BRISQUE)**

- **MOS(Mean Opinion Score)**
  - 어떤 이미지에 대하여 사람이 직접 매긴 점수를 평균내어 image quality 점수로 활용
  - 1(bad) ~ 5(good) → 클수록 이미지 품질이 좋음

- **DMOS(Differential Mean Opinion Score)**
  - 원본 이미지와 왜곡 이미지 사이의 MOS 차이 → 작을수록 왜곡 이미지의 품질이 좋음

- **MSCN(mean Subtraction and Contrast Normalization)**
  - 이미지의 불필요하게 반복되는 부분들을 제거하면서, 중요한 부분을 비선형적인 방식으로 남기는 이미지 전처리 방식
    1. 입력 이미지가 color이라면 grayscale으로 변환한다.
    2. Gaussian kernel을 활용하여 각 pixel의 local mean과 local std을 구한다.
    3. 픽셀마다 **(픽셀 밝기 - 픽셀 mean)/픽셀 std** 으로 전체 이미지를 표준화한다.
  - 일반적으로 **자연 이미지**에서는 MSCN 결과를 히스토그램으로 나타냈을 때, **히스토그램이 가우시안 분포를 따르는 것**으로 알려져 있다.

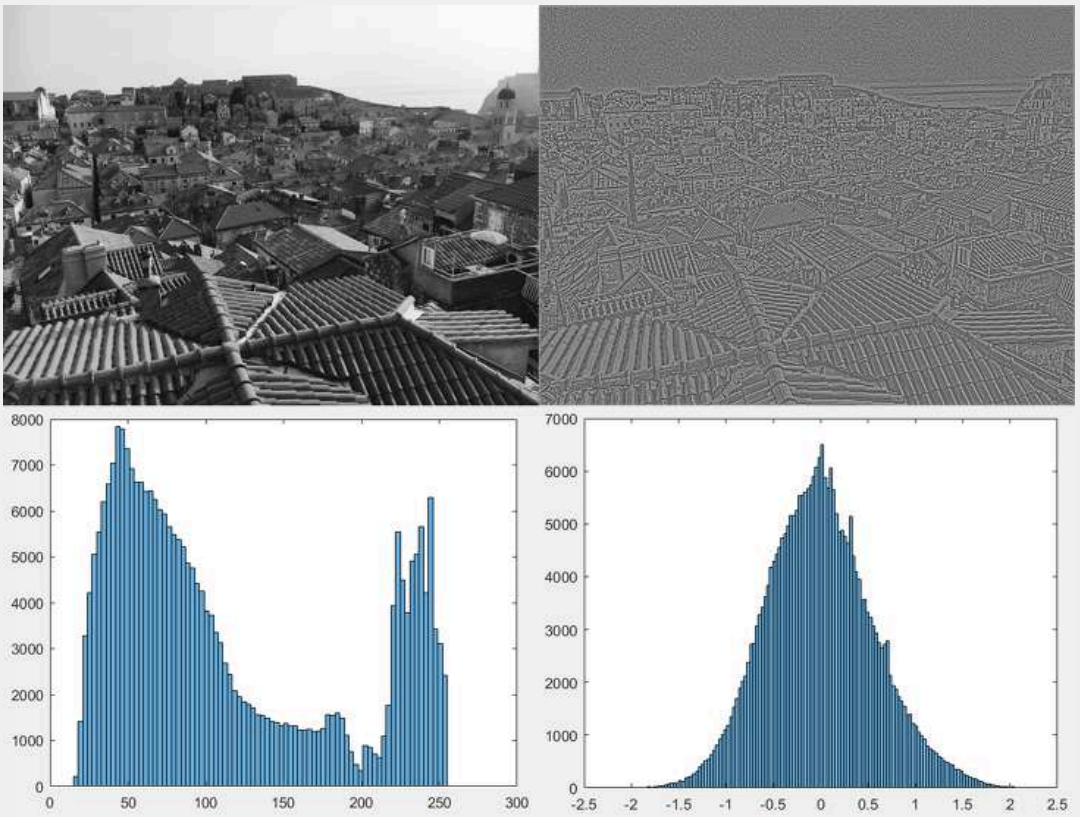

https://bskyvision.com/entry/MSCNmean-subtraction-and-contrast-normalization의-이해#google_vignette

- NSS (Natural Scene Statistics)
  - MSCN 결과로부터 얻을 수 있는 36-dimensional image feature

- **BRISQUE**
  - **NSS feature → DMOS**를 예측하도록 학습된 **SVM**을 사용하여 이미지의 품질을 평가한다.
  - **BRISQUE score가 작을수록 좋은 이미지 품질(왜곡이 적은 이미지)**임을 시사한다.

▼ **Nautral image quality evaluator (NIQE)**

- BRISQUE score와 유사하게 **NSS를 입력**으로 사용하여 이미지의 품질을 평가하는 방식
- 학습된 SVM을 사용하는 BRISQUE와는 달리, **NIQE는 학습 기반의 metric이 아니다.**
- 이미지에 MSCN을 적용한 후, 패치 단위로 분할하고, 일부 패치만을 선택하여 local mean and local std을 구하여 해당 이미지의 품질을 대표하게 한다.

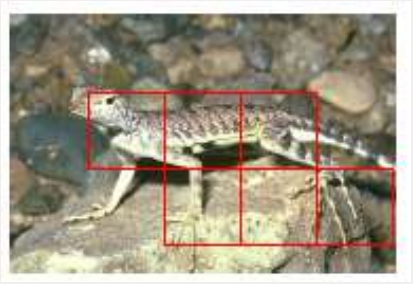

- 대규모 고품질 자연 이미지에 대해 feature들의 평균 벡터와 공분한 행렬을 미리 구축해둔다.
- 이후 테스트 과정에서는
  미리 구축된 평균 벡터와 공분산 행렬 ↔ 평가 대상 이미지의 평균 벡터와 공분산 행렬
  간의 **유사도를 비교**한다.
- 따라서 **작은 NIQUE 값이 좋은 이미지 퀄리티**를 시사한다.

▼ **CLIP Score**

- Text-image similarity

4.2. Comparisons

- **Higher-quality 3D scenes** : 제안된 방법은 baseline 모델들보다 **낮은 BRISQUE와 NIQE**를 보였다.
- **Semantic relevance** : 제안된 방법은 baseline 모델들보다 **높은 CLIP score**를 보였다.

Methods	CLIP-Mesh	SJC	DreamFusion	DreamFusion-Scene	3DP	PixelSynth	Text2Room	**Ours**
Guidance Type	S	S	S	S	I	I	I	I
3D Representation	Mesh	NeRF	NeRF	NeRF	LDI&Mesh	Point Cloud	Mesh	NeRF
Opti. time (hours)	0.206	0.429	1.148	1.510	0.125	0.409	0.365	1.525
BRISQUE ↓	46.266	39.543	67.012	37.799	30.592	25.924	28.395	**24.498**
NIQE ↓	6.652	11.971	12.022	6.402	6.260	6.604	5.415	**4.618**
CLIP Score ↑	27.480	24.152	22.576	28.032	27.376	27.267	28.056	**28.695**

Table 1. Quantitative results

- `CLIP-Mesh`, `SJC`, 그리고 `DreamFusion`은 3D object generation에 초점이 맞춰져 있기 때문에 scene 단위 생성에는 한계가 있었다.
- `DreamFusion-Scene`
  - 장면 단위 3D scene 생성은 성공하였음

    - 세부적인 구조를 충분히 구현하지 못함
    - 사실적인 텍스처 표현에 한계
    - **high-level semantic prior**만으로는 저수준 세부 정보를 충분히 전달할 수 없기 때문으로 보임
- `3DP`, `PixelSynth`
    - Text-image 모델이 생성한 **이미지**를 사용하여 3D 장면을 복원하는, novel view synthesis 기반의 전략 사용
    - 텍스처 세부 정보 보존에서 강점 → 장면의 품질과 사실성에서 강점
    - **제한된 시점** 안에서만 렌더링을 수행할 수 있음
    - **novel view synthesis 과정은 입력 프롬프트와 독립적**으로 이루어지기 때문에, 일부 새로운 시점에서는 **의미적으로 일관되지 않는 내용을 생성**할 수 있음
- `Text2Room`
    - 제안된 방법과 유사하게, **text-conditioned diffusion model을 인페인팅 모듈로 활용**하여 3D 장면의 누락 영역을 채움
    - 생성 장면이 **mesh로 표현**됨 → **depth discontinuity**가 있는 영역에서 **stretched geometry**를 자주 만들어내는 경향을 보임

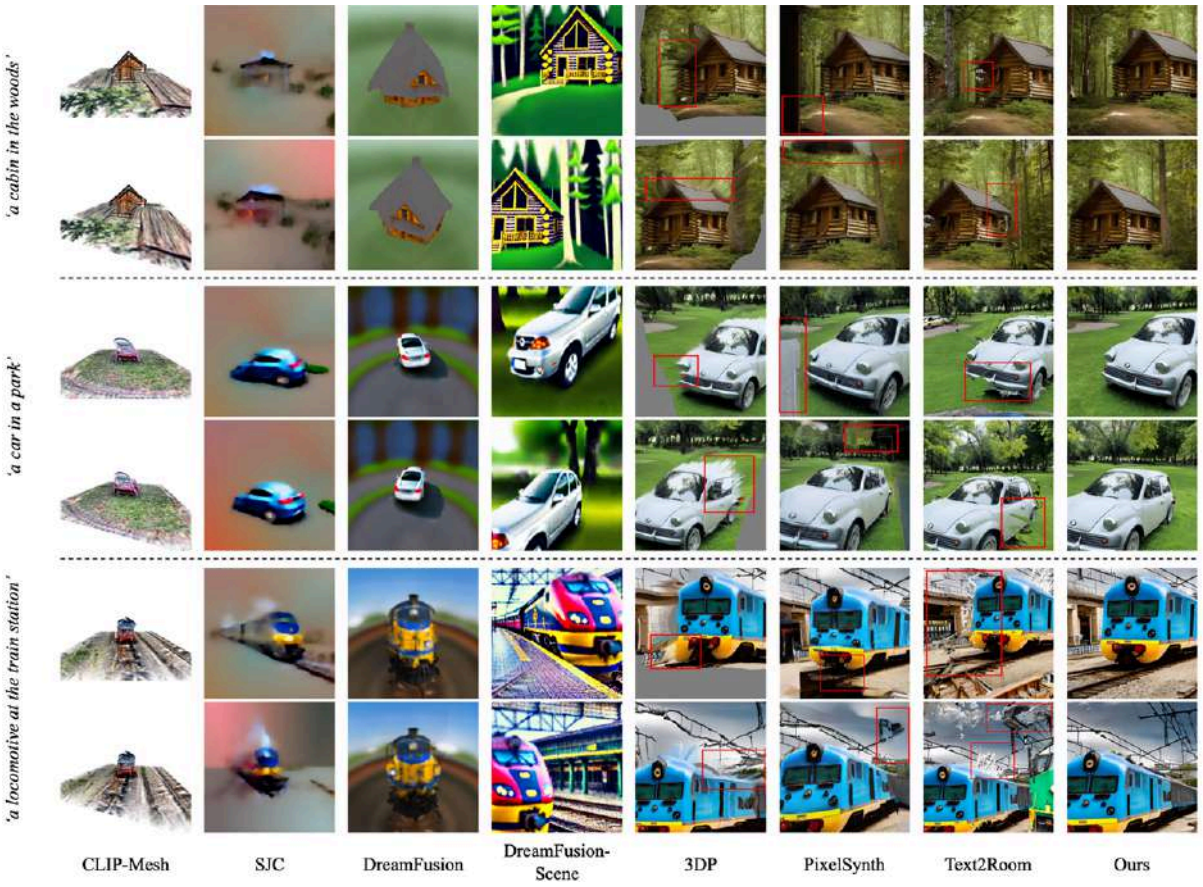

Figure 5.

▼ **Text2NeRF의 생성 결과**

- **다양한 시야에서 3D scene 렌더링 가능(360도)**

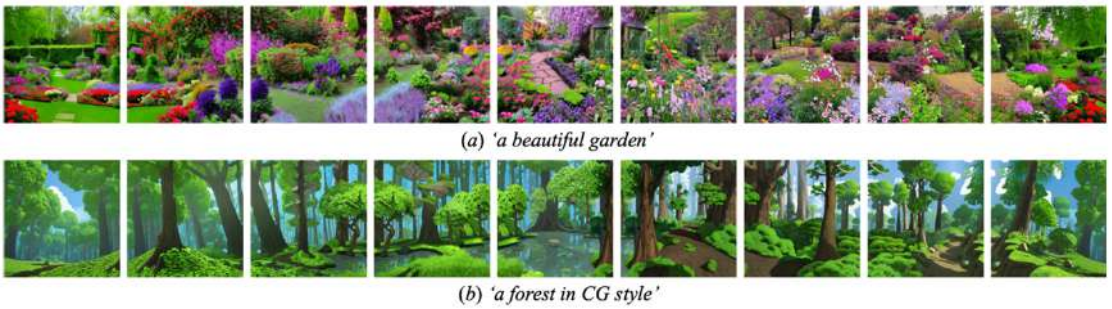

Figure 6

- **사실적인 이미지**

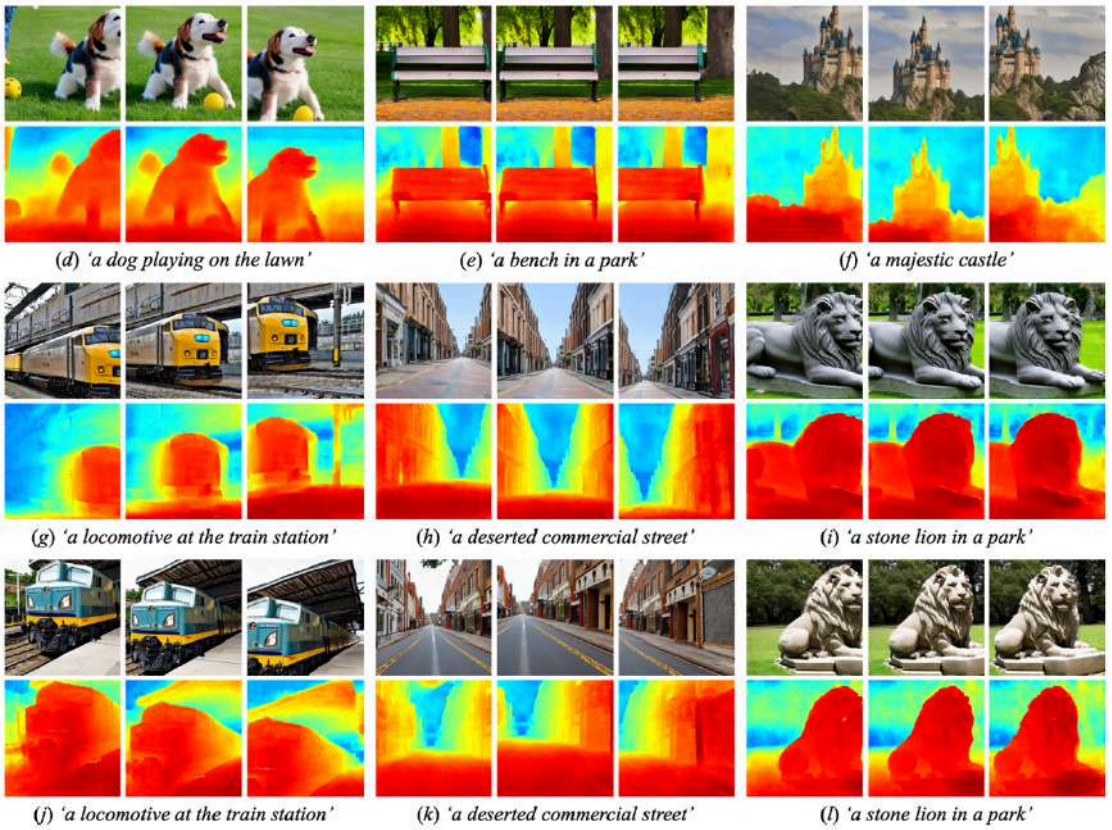

Figure 7

- **예술적 스타일**

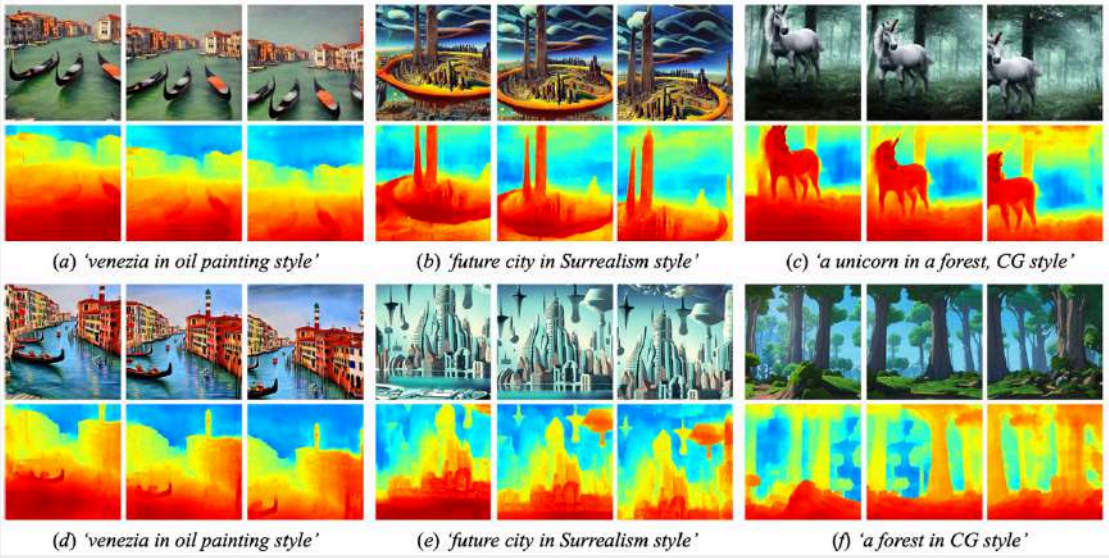

Figure 8

4.3. Ablation Studies

Methods	Ours (full)	w/o PIU	w/o Support Set	w/o Depth Loss	w/ *GNLL* Depth Loss	w/ *SSI* Depth Loss	w/o Depth Align.	w/o Local Depth Align.	w/o Glob Depth Ali
BRISQUE ↓	**24.498**	33.8434	28.3389	27.0617	26.1802	25.8995	28.1771	27.9174	27.1946
NIQE ↓	**4.618**	6.012	5.778	5.588	4.837	4.711	5.945	5.209	4.839
CLIP Score ↑	**28.695**	25.733	26.330	26.782	27.168	27.126	26.173	26.527	26.811

Table 2. Ablation studies on key components of our method.

Ablation on PIU Strategy

- PIU를 적용하지 않고, **각 view에 대해서 독립적인 inpainting을 수행**할 경우, 시점 간 일관성이 없는 inpainting 결과들이 NeRF에 반영된다.
- 그 결과, **겹치는 영역에서 심각한 artifact**가 발생한다.

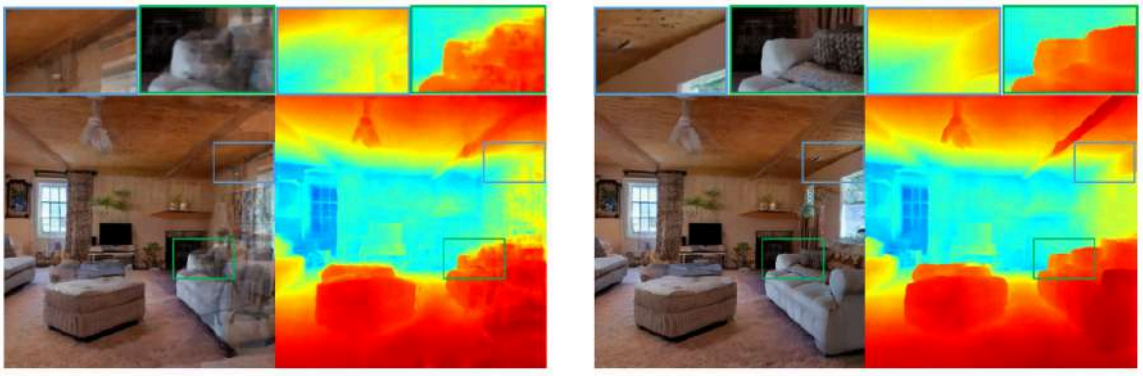

(*a*) w/o PIU Strategy (*b*) w/ PIU Strategy

Ablation on Support Set

- **(a)**: Support set 없이, 각 시점의 **이미지 한 장만으로 NeRF 학습**
    - **학습에 사용된 시점에는 과적합**, **새로운 시점**에서는 **선명하지 않은 이미지** 생성

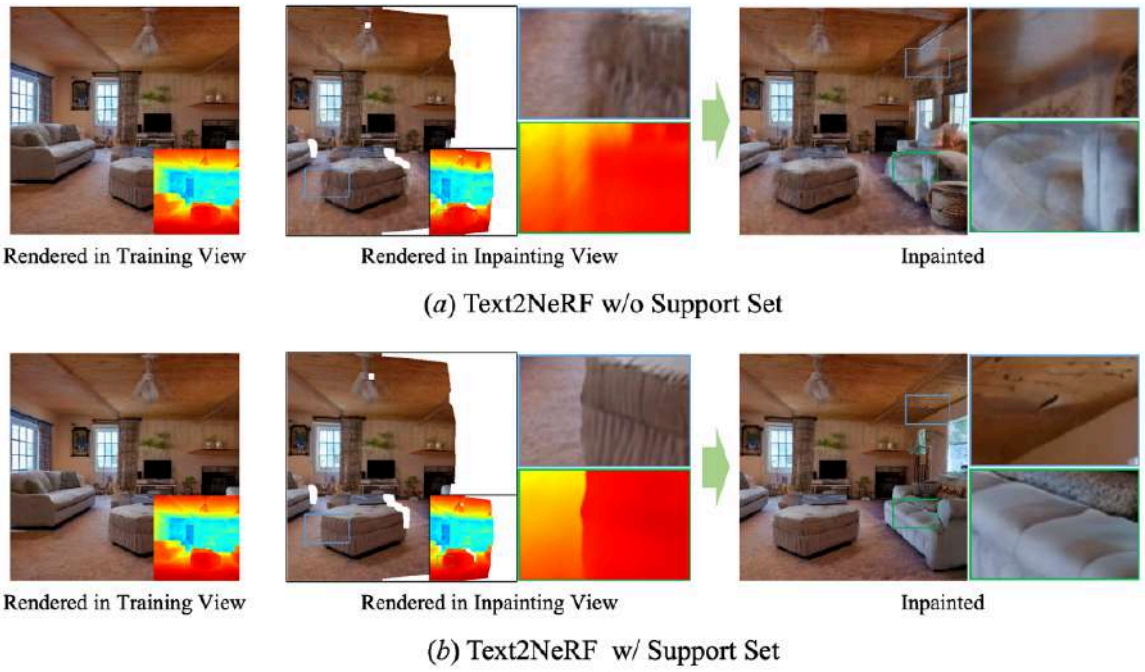

Figure 10.

- Support set 생성 시 **샘플링 개수 ξ와 시점 이동 거리(radiance) ζ에 대한 ablation study**
    - 계산 비용과 학습 이득 사이의 균형을 고려하여 $\xi = 8$으로 결정
    - 가장 좋은 성능을 보인 $\zeta = 0.2$로 결정

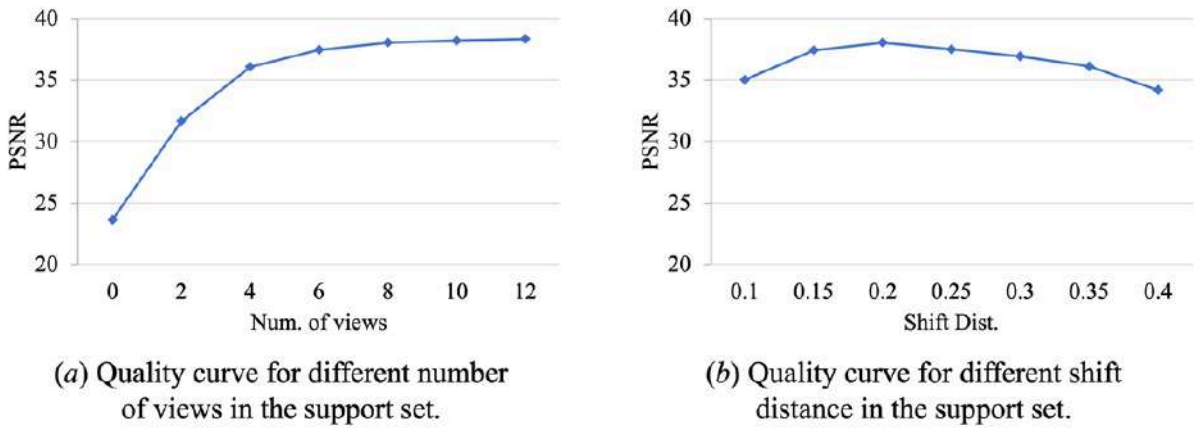

Figure 11.

Ablation on Depth Loss

- **제안된 L2 거리 기반 depth loss를 기존의 depth loss들과 비교**한다:
    - GNLL : Gaussian Negative Log Likelihood

- SSI : Scale and Shift Invariant
- Depth loss가 아예 적용되지 않은 경우: 그럴듯한 기하 구조를 갖는 새로운 시점을 합성하는 데 한계
- Proposed L2 depth loss > GNLL, SSI

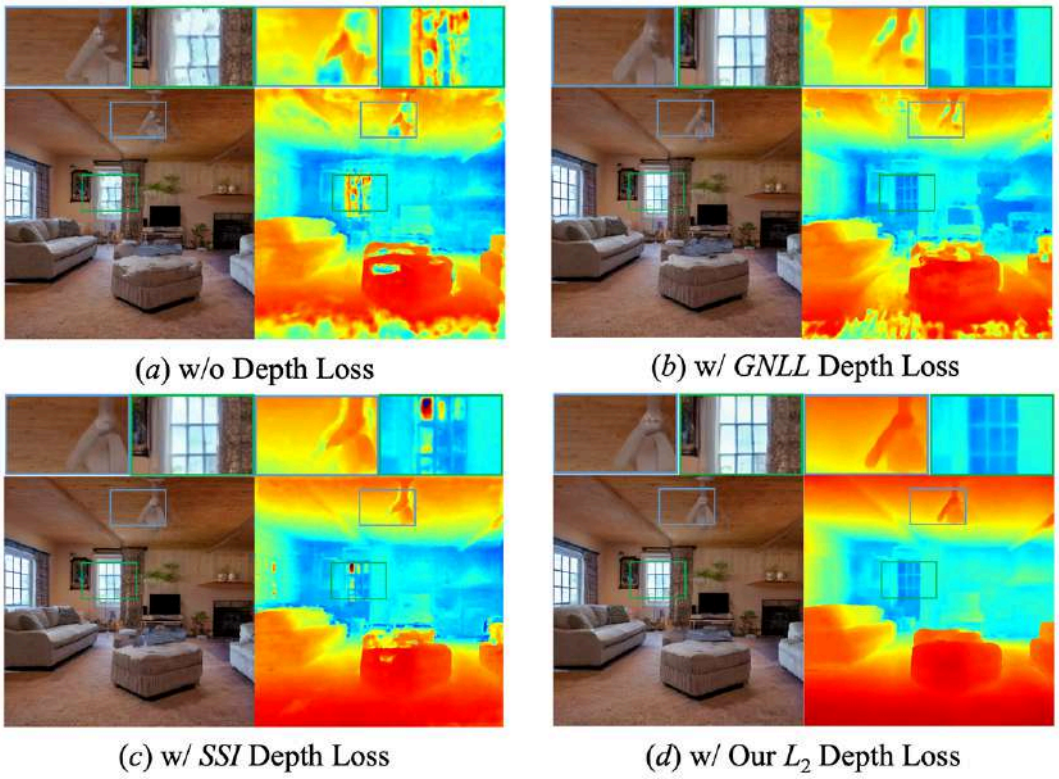

Figure 12.

Ablation on Depth Alignment

- **(a) : Depth alignment가 아예 적용되지 않음**
  - 서로 다른 시점 간의 depth 불일치로 급격한 depth 변화가 관찰됨
- **(b) : Global depth alignment만 적용**
  - 전반적으로 align되나 미세 디테일 부족
- **(c) : Local depth alignment만 적용**
  - 일정 부분 align되지만 완전히 해소되지 않음
- **(d) : Two-stage depth alignment를 온전히 적용**
  - 경계선 부근에서 더 부드럽고 조화로운 depth 분포

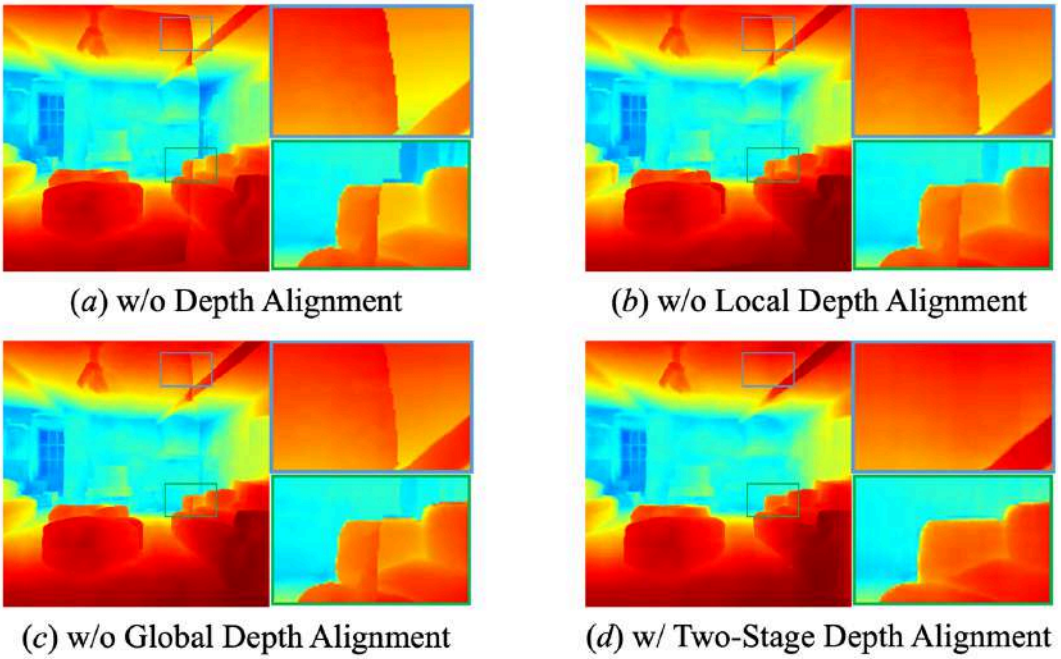

Figure 13.

5. Conclusion

Summary

본 논문에서는 텍스트 프롬프트만으로 복잡한 구조와 사실적인 텍스처를 갖는 다양한 3D 장면을 생성할 수 있는 Text2NeRF를 제안하였다.

제안된 방법은 먼저 **사전학습된 diffusion model**을 활용하여 **content prior(이미지) I_0를 생성**한다.

생성된 이미지에 **사전학습된 monocular depth estimation model**을 적용하여 **depth map D_0**을 얻고, 이를 **geometry prior**으로 사용한다.

초기 camera pose P_0을 기준으로 support set을 구성한 뒤, **초기 3D scene**을 만들고, **NeRF를 초기 scene에 대하여 최적화**한다.

이후 **다른 시점들 P_k**에 대하여 **차례로 NeRF를 학습**시키는 **PIU 전략**을 사용하여 다중 시점에서의 일관성을 가진 NeRF를 최적화한다.

NeRF 최적화 과정에서 RGB loss와 함께 **depth loss** 및 **transmittance loss**를 사용하여 **depth-aware NeRF optimization**을 수행한다.

서로 다른 시점에서 추정된 **depth disparity**를 제거하기 위해 **two-stage depth alignment** 전략을 제안하였다.

이처럼 정교하게 설계된 모듈과 목적함수 덕분에, **Text2NeRF**는 **복잡한 기하 구조와 고충실도 텍스처**를 갖는 사실적이고 다양한 3D 장면을 생성할 수 있다.

Limitation

장면 생성 실험에서 인상적인 결과를 보였음에도 불구하고, 저자들은 본 방법이 **매우 큰 가림(occlusion)이 존재하는 장면에서는 여전히 어려움을 겪는다**는 점을 인정한다.

이는 **깊이 추정의 정확도가 제한적**이기 때문이다.

부정확한 깊이 추정은 **DIBR** 기반 워핑 시점에서 눈에 띄는 **기하 왜곡**을 유발하며, 이러한 왜곡은 카메라 위치 이동량이 커질수록 더욱 두드러진다.

그 결과 인페인팅 단계에서 뚜렷한 artifact와 비현실성이 발생하게 되며, 이는 본 방법이 합리적인 결과를 생성하기 어렵게 만든다.

반면, **깊이 추정 기술이 발전**한다면 이러한 한계는 효과적으로 완화될 수 있다.

Initial View　　Warped View (Camera Shift = 0.2)　　Warped View (Camera Shift = 0.4)

Mesh 또는 PCD 기반 생성 방법들과 비교할 때, 본 방법은 기존 NeRF 기반 방법들과 마찬가지로 **더 긴 최적화 시간**이 필요하다(약 1.5시간).

저자들은 **넓은 시점 범위**에서 3D 장면을 생성하기 위해 **카메라 위치를 radiance field 내부**에 두고 **바깥을 바라보도록** 설정하였다.

이로 인해 본 방법은 카메라가 안쪽을 바라보는 다른 방식들과 달리 **개별적인 3D 객체를 생성할 수 없다**.

이러한 한계를 극복하기 위해, 향후에는 **장면에 적응적으로 동작하는 유연한 카메라 설정 전략**을 프레임워크에 도입할 수 있을 것이다.